

Дизайн эксперимента

В качестве источника данных используется датасет **M4**, в эксперимент включаются только **monthly-ряды**. Это позволяет зафиксировать единый сезонный период и сопоставимо сравнивать модели и признаки. При смешивании рядов разной частоты сезонность, горизонт прогноза и сезонные признаки уже нельзя интерпретировать одинаково.

Из **monthly-части M4** отбираются только ряды достаточной длины для работы. Далее для каждого ряда проверяется наличие выраженной годовой сезонности. Критерий отбора основан на **ACF на лаге 12** - для **monthly-рядов** этот лаг естественно соответствует годовому сезонному циклу. Ряд включается в эксперимент, если значение **ACF на лаге 12** статистически значимо относительно стандартных 95%-границ.

Дополнительную предобработку перед отбором сознательно не делаем. Понятно, что значимый **ACF(12)** может быть связан не только с «чистой» сезонностью, но и с трендом или общей автозависимостью. Но для этой работы такого критерия достаточно: нам важно, чтобы в ряде была выраженная годовая повторяемость хотя бы в каком-то виде. После фильтра случайным образом выбираются 200 рядов.

Пусть длина ряда равна M . В работе фиксируются сезонный период $m=12$, горизонт прогноза $h=12$ и длина входной истории $L=36$. Это базовая постановка: один полный год прогноза и три полных годовых цикла во входе.

Разбиение у всех моделей одинаковое: первые $M-h$ наблюдений образуют обучающую часть, последние h — финальный **holdout-горизонт**. Для бейзлайнов этого достаточно: они обучаются на первых $M-h$ точках и строят прогноз на последние h .

Для **ML-модели** используется та же обучающая часть, но дополнительно формируется технический хвост ряда. В базовой постановке его длина равна $L+h$, а на втором этапе он увеличивается под проверяемые значения **history**. На его основе строятся **holdout_fit**, **holdout_pred** и **truth**. Это позволяет сравнивать разные спецификации признаков и параметры **forecasting pipeline** на одном и том же последнем **holdout-отрезке**.

В качестве бейзлайнов используются **Naive**, **SeasonalNaive**, **AutoETS** и **AutoTheta**. Все они обучаются на **train block** и строят прогноз на **holdout block** длины $h=12$.

Для основной **ML-модели** используется стратегия **direct MIMO forecasting**, то есть прогноз строится сразу для нескольких будущих значений. Такой подход теоретически уменьшает эффект ошибки в сравнении с рекурсивной схемой и позволяет чище сравнивать способы кодирования сезонности.

(Я бы хотел честное крутое исследование относительно того какая архитектура лучше - но в рамках вопроса где у нас случайные ряды- строить более серьезную модель лучше отвечающую задаче - мыло смысла)

Проверка гипотез строится в четыре этапа.

- 1) На первом этапе при фиксированных `history` и `model_horizon` сравниваются разные способы кодирования сезонности: обычные лаги, лаги с сезонными лагами, лаги с календарными признаками, лаги с Fourier-признаками и их комбинации.
- 2) На втором этапе для каждой спецификации отдельно анализируется влияние параметров `history` и `model_horizon`. С его помощью хочу понять, сохраняется ли внутри одной кодировки устойчивый эффект длины входной истории и длины прямого прогнозного блока, и отличается ли этот эффект между разными способами задания сезонности.
- 3) На третьем этапе сравнивается устойчивость результатов: какая спецификация чаще оказывается лучшей и насколько она чувствительна к изменению параметров `forecasting pipeline`.
- 4) На четвертом этапе выбирается лучшая итоговая ML-конфигурация, для которой строится прогноз на `holdout_pred`, после чего он сравнивается с `truth`. Затем эта конфигурация сопоставляется с бейзлайнами.

Для оценки качества прогнозов используются две основные метрики:

- **sMAPE**
- **MASE**

Обе метрики являются **безразмерными**, что важно - в эксперименте участвуют ряды разного масштаба. Для сравнения моделей ошибки сначала рассчитываются **по каждому ряду отдельно**, а затем усредняются по всей выборке, применяются для выбора лучшей модели.

Идея использовать единый эконометрический подход для сравнения ошибок моделей и для унификации ответа - в духе Diebold-Mariano test - рассматривалась, однако в итоговой постановке от него было решено отказаться. В работе сравниваются не только разные модели, но и разные схемы прогнозирования внутри одной ML-архитектуры: могут меняться `history`, `model_horizon` и число прямых MIMO-блоков. В результате одни модели будут видеть больше будущих данных, чем другие. В такой схеме применение DM test или подобных становится менее прозрачным и может создавать иллюзию более строгого вывода который вряд ли допустим.

Архитектура моделей

Для реализации эксперимента был собран набор отдельных функций, покрывающих основные части пайплайна: загрузку и отбор рядов, разбиение данных, расчет бейзлайнов, генерацию признаков, построение окон для direct MIMO-прогнозирования, обучение CatBoost, расчет метрик и визуализацию результатов. Такой подход позволил не писать весь эксперимент одним большим блоком, а разделить его на понятные части и тестировать их отдельно.


Итоговая схема состоит из двух уровней. Первый — вспомогательные модули для работы с данными, признаками, прогнозными окнами и оценкой качества. Второй — исследовательский ноутбук, где эти функции последовательно используются для

запуска всех этапов эксперимента. Такая структура упрощает отладку, проверку промежуточных результатов и воспроизводимый запуск исследования.




Эксперимент

В соответствии с описанным выше из `monthly`-части датасета `M4` была сформирована случайная выборка из 200 временных рядов, удовлетворяющих критерию сезонности. Отобранные ряды заметно различаются по длине, масштабу и форме динамики.

	length
count	48000.000000
mean	234.300229
std	137.406295
min	60.000000
25%	100.000000
50%	220.000000
75%	324.000000
max	2812.000000



На «нулевом» этапе в качестве ориентиров были рассчитаны четыре бейзлайна. По средним значениям метрик лучшими оказались `AutoETS` и `AutoTheta`. эти две автоматические статистические модели рассматриваются как основные точки отсчета для дальнейшего сравнения с `ML`-подходом



На первом этапе сравниваются шесть спецификаций признаков при фиксированных параметрах `history=36` и `model_horizon=4`. Базовый вариант включает только обычные лаги (1, 2, 3, 6), а остальные спецификации добавляют к нему один из способов задания сезонности: сезонные лаги (12, 24), календарные признаки (`month`, `quarter`), Fourier-признаки или их комбинации. Здесь проверяется, какой именно способ кодирования сезонности дает наилучший результат при неизменной `forecasting-схеме`.


Если ориентироваться на основные метрики качества, то лучшей спецификацией на первом этапе оказался вариант `lags_seasonal_fourier`. Он показал минимальные средние значения как *MASE*, так и *sMAPE*. Очень близко к нему расположились `lags_seasonal` и

lags_seasonal_calendar, тогда как lags_only и особенно lags_calendar выглядели слабее. Хотя в смысле частоты выигрыша lags_fourier выделяется чуть более устойчивой победой.

	mean_smape	median_smape	mean_mase	median_mase	n_series	model
0	8.144990	4.022777	1.088959	0.803836	200	lags_seasonal_fourier
1	8.216628	4.163428	1.098513	0.810589	200	lags_seasonal
2	8.221393	4.039148	1.099901	0.835900	200	lags_seasonal_calendar
3	8.169273	4.061358	1.114789	0.806314	200	lags_fourier
4	8.245062	4.345446	1.129180	0.842911	200	lags_only
5	8.283831	4.395723	1.152144	0.827963	200	lags_calendar

	model	n_wins	share_wins
0	lags_fourier	42	0.210
1	lags_seasonal_calendar	36	0.180
2	lags_seasonal_fourier	36	0.180
3	lags_seasonal	31	0.155
4	lags_only	29	0.145
5	lags_calendar	26	0.130

	model	n_wins	share_wins
0	lags_fourier	42	0.210
1	lags_seasonal_calendar	35	0.175
2	lags_seasonal_fourier	35	0.175
3	lags_seasonal	31	0.155
4	lags_only	29	0.145
5	lags_calendar	28	0.140




В целом – явное кодирование сезонности действительно улучшает качество прогноза. Если выбирать только один способ задания сезонности, то наилучшим вариантом выглядят Fourier-признаки. При этом максимальное среднее качество достигается уже не при одной кодировке, а при совместном использовании нескольких способов задания сезонности, то есть в комбинации обычных лагов, сезонных лагов и Fourier-признаков.

Результат первого этапа пока нельзя считать универсальным, поскольку сравнение проводилось только при одной фиксированной комбинации history и model_horizon.

На втором этапе мы для каждого способа кодирования проверяем эффект от history и horizon.

По результатам наиболее устойчивый эффект связан с длиной входной истории. Почти для всех спецификаций увеличение history улучшает качество прогноза, а лучшие результаты чаще всего достигаются при history=48. Для monthly-рядов это кажется естественным, так как так модель уже видит четыре полных годовых цикла, и этого обычно достаточно, чтобы устойчивее восстановить повторяющиеся паттерны.






(Пример запуска для lags_seasonal_fourier)

Влияние `model_horizon` оказалось менее однозначным. Для спецификаций без фурье признаков серьезного отличия нет. Для `lags_fourier` слишком большой прямой блок может ухудшать качество, а для `lags_seasonal_fourier` лучший результат достигается уже при `model_horizon=4-6` в зависимости от метрики. Возможно это объясняется тем, что Fourier-признаки задают сезонность как гладкую периодическую структуру, поэтому при изменении длины прямого блока меняется и то, насколько удачно эта форма переносится на будущий участок горизонта.

В итоге эффект длины истории кажется устойчивым и почти универсальным, тогда как эффект `model_horizon` зависит от способа кодирования сезонности и заметнее проявляется в моделях с Fourier-признаками.

На третьем этапе результаты свел результаты в общие heatmap по всем спецификациям и комбинациям параметров.



Эти heatmap используются скорее как обобщающая иллюстрация, которая подтвердила прошлый тезис.

Результаты второго шага агрегируются по всей сетке параметров `history` × `model_horizon`, чтобы сравнить модели не в одной фиксированной точке, а по совокупности настроек `forecasting pipeline`. В такой постановке можно оценить, какие спецификации выглядят более универсальными в среднем, какие дают лучший результат в отдельных точках и насколько устойчивыми остаются выводы при смене параметров.

Top-3 by average MASE over grid

	config_name	avg_grid_mase	avg_grid_smape	mase_range	smape_range
0	lags_seasonal	1.471226	10.775238	0.791169	5.372076
1	lags_only	1.474708	10.700913	0.706404	5.098221
2	lags_calendar	1.477858	10.731319	0.732548	5.222981

Top-3 by average sMAPE over grid

	config_name	avg_grid_mase	avg_grid_smape	mase_range	smape_range
0	lags_fourier	1.481945	10.672810	0.748688	5.245831
1	lags_only	1.474708	10.700913	0.706404	5.098221
2	lags_calendar	1.477858	10.731319	0.732548	5.222981

Top-3 by best MASE on grid

	config_name	best_grid_mase	best_grid_smape	mase_range	smape_range
0	lags_seasonal	1.078867	8.156302	0.791169	5.372076
1	lags_seasonal_fourier	1.101042	8.220291	0.772093	5.363789
2	lags_seasonal_calendar	1.104312	8.271788	0.779169	5.394261

Top-3 by best sMAPE on grid

	config_name	best_grid_mase	best_grid_smape	mase_range	smape_range
0	lags_seasonal	1.078867	8.156302	0.791169	5.372076
1	lags_fourier	1.115546	8.180272	0.748688	5.245831
2	lags_seasonal_fourier	1.101042	8.220291	0.772093	5.363789

На третьем этапе наиболее универсальной спецификацией оказалась `lags_seasonal`. Она показала лучший `avg_grid_mase`, а также лучшую точку на всей сетке и по `MASE`, и по `sMAPE` — `history=48`, `model_horizon=1`.

Среди других сильных вариантов выделялись `lags_fourier`, `lags_seasonal_fourier` и `lags_seasonal_calendar`. При этом `lags_fourier` показал лучший `avg_grid_smape`, но в среднем по `MASE` уступил `lags_seasonal`.


Итоговый вывод: явное кодирование сезонности полезно, а наиболее универсальной архитектурой в рамках эксперимента выглядит `lags_seasonal`

	model	mean_smape	median_smape	mean_mase	median_mase	n_series
0	AutoETS	6.458918	3.122006	0.754907	0.621262	200
1	AutoTheta	6.323814	2.936599	0.762348	0.616357	200
2	lags_seasonal_best	8.156302	3.996021	1.078867	0.783107	200
3	lags_seasonal_fourier_best	8.255754	4.242735	1.101042	0.811595	200

	model	n_wins	share_wins
0	AutoETS	75	0.375
1	AutoTheta	70	0.350
2	lags_seasonal_best	29	0.145
3	lags_seasonal_fourier_best	26	0.130

	model	n_wins	share_wins
0	AutoETS	76	0.380
1	AutoTheta	69	0.345
2	lags_seasonal_best	31	0.155
3	lags_seasonal_fourier_best	24	0.120

В финальном сравнении лучшие ML-конфигурации бейзлайны не обошли.



и по средним метрикам, и по числу побед снова лучше выглядели AutoETS и AutoTheta. Внутри самих ML-моделей картина тоже не поменялась — более надежным вариантом остался lags_seasonal, а добавление Fourier-признаков в среднем не дало выигрыша.

Ряды у нас monthly и явно сезонные, а на таких данных хорошие статистические бейзлайны часто очень сильны и обыграть их простой глобальной ML-моделью непросто

Выводы

(в рамках данного эксперимента) **Сезонность лучше моделируется через явное добавление сезонных признаков, а не только через обычные лаги.** На фиксированной постановке лучший результат могут дать разные комбинации, но в среднем по разным

настройкам наиболее универсальной оказалась более простая спецификация с сезонными лагами. Для себя я делаю вывод, что комбинации признаков могут давать максимум качества, но именно сезонные лаги дают более стабильный выигрыш. Из параметров сильнее всего влияла длина входной истории: почти во всех случаях более длинное окно улучшало прогноз. Влияние `model_horizon` оказалось слабее и заметнее проявлялось в моделях с Fourier-признаками. При этом сильные статистические бейзлайны (AutoETS, AutoTheta) обыграть не удалось, поэтому для `monthly`-рядов с выраженной сезонностью они остаются очень сильным ориентиром.

Полученный результат в определенной степени ожидаем, ведь в исследование изначально были отобраны ряды с выраженной сезонностью по критерию `ACF(12)`, вероятно было бы бессмысленным применять сезонные признаки к любому ряду без разбора.

У такого анализа есть сильное ограничение в том, что все выводы получены при фиксированном общем горизонте `h=12`, то есть только для одного годового отрезка. Допускаю, что в сравнении с тестом способа кодировки признаков - эффект от горизонта и истории может быть серьезнее связан с горизонтом прогноза

Такое сравнение остается ограниченным, поскольку сама сетка для оценки наиболее стабильного способа невелика и включает лишь несколько заранее выбранных значений параметров. Допускаю, что часть признаков может вести себя по-разному на разных горизонтах, например, Fourier-признаки.